

M I R O I R

Bloc 4

Solutions d'intelligence artificielle

Industrialisation de bout en bout d'un moteur de recommandation : conception, serving, CI/CD, réentraînement et monitoring.

Prince Néhémie · École des Mines · Juin 2026

github.com/princebn/miroir

C O N T E X T E

Miroir : SaaS B2B de conseil en image

Le Bloc 4 transforme les signaux du pipeline en recommandations personnalisées, validées par la conseillère.

PERSONA — AÏCHA

- Conseillère indépendante
- ~30 clientes premium (Europe + Afrique)
- Profil pro : haute rotation, exigence forte

PAIN PRINCIPAL

- 60 % du temps en recherche produit
- 44 419 articles au catalogue
- Le catalogue scale, la conseillère ne scale pas

VALEUR MIROIR

- Recos personnalisées, décision humaine finale
- ~10 h / semaine gagnées par conseillère

LE BLOC 4 DANS LE TOUT

- Reçoit les signaux temps réel du Bloc 3
- Sert le modèle ML qui industrialise le conseil

Objectif & compétences évaluées

6 compétences RNCP — toutes couvertes par les livrables de ce bloc.

- | | | |
|---|---|---|
| 1 | Cahier des charges de la solution d'IA | Persona, besoin métier, contraintes, périmètre B2B (RGPD). |
| 2 | Algorithme adapté aux données | Reco 2 étages : retrieval CLIP/pgvector + re-ranker LightGBM. |
| 3 | Infrastructure de serving (API) | FastAPI, alias MLflow @production, latence p95 < 300 ms. |
| 4 | Pipelines CI/CD de déploiement | GitHub Actions : lint, tests, build image, gate qualité. |
| 5 | Réentraînement automatisé | DAG Airflow hebdo : qualité → train → promotion conditionnelle. |
| 6 | Pilotage par le monitoring | Drift Evidently (double critère) + dashboard Grafana. |

Recommandation de bout en bout

Deux étages enchaînés : rappel large par similarité, puis classement fin et diversifié.



RETRIEVAL – RAPPEL VISUEL

- 44 419 embeddings CLIP ViT-B-32 indexés (HNSW, cosinus)
- Ancre construite depuis saison colorimétrique + archétypes
- 200 candidats proches du profil et de l'occasion

RE-RANKING – CLASSEMENT FIN

- LightGBM, 37 features (cliente × produit × occasion)
- Diversification : max 2 par type, max 3 par couleur
- Top-k servi + boucle de feedback humain

Technologies & versions

Versions verrouillées, choix de stabilité documentés par ADR.

MODÈLE ML

LightGBM + CLIP (open_clip ViT-B-32), scikit-learn

REGISTRY

MLflow 3.x — tracking, registry, alias @production

SERVING

FastAPI + Uvicorn — /recommend, /feedback, /similar

VECTORIEL

PostgreSQL 16 + pgvector (HNSW) — réutilisé du Bloc 2

CI/CD

GitHub Actions — ruff, black, pytest (72), build Docker

ORCHESTRATION

Apache Airflow 2.10.5 — DAG de réentraînement hebdo

MONITORING

Evidently 0.7 (drift) + Prometheus + Grafana

Re-ranker LightGBM — performances mesurées

37 features, sélection par AUC de validation, gestion du déséquilibre (scale_pos_weight).

0,876

AUC (test)

[MESURÉ]

0,80

Average Precision

[MESURÉ]

0,42

NDCG@5

[MESURÉ]

0,56

Recall@5

[MESURÉ]

DÉMARCHE

- Amorçage par interactions synthétiques (cold start), taux d'approbation ~16 % — tracé [SYNTHÉTIQUE].
- Performances à lire comme preuve d'architecture ; la finesse viendra du feedback réel via /feedback.
- Importance des features exploitable (interprétabilité) — défendable en soutenance.

FastAPI — le modèle servi en production

Chargement via alias MLflow : promotion et rollback sans redéploiement.

ENDPOINTS

- POST /recommend — top-k pour cliente × occasion
- POST /feedback — capture la décision (boucle d'apprentissage)
- DELETE /feedback — annulation (rail vidé par la conseillère)
- GET /similar — voisinage visuel CLIP (pgvector)
- GET /clients, GET /images, GET /health

PROPRIÉTÉS

- Modèle chargé via models:/miroir_reranker@production
- Promotion / rollback = simple déplacement d'alias MLflow
- Validation typée (Pydantic), bornes sur les listes
- Métriques Prometheus exposées sur tous les endpoints

PERFORMANCE


253 ms

latence p95 · objectif < 300 ms atteint

[MESURÉ]

Pipeline d'intégration continue

Chaque push est vérifié : aucune régression ne passe silencieusement.




GARANTIES

- 72 tests verts exigés avant tout merge — la qualité bloque le pipeline.
- Versions d'outils verrouillées (ruff 0.15.16, black 24.4.2) pour des builds reproductibles.
- Image Docker construite et prête au déploiement Kubernetes (manifestes versionnés).

DAG hebdomadaire à promotion conditionnelle

Un réentraînement automatique ne doit jamais dégrader la production silencieusement.



RÈGLE DE PROMOTION

- Challenger promu seulement si $AUC \geq AUC \text{ champion} - 0,005$; sinon rollback (champion conservé).
- Great Expectations bloque l'entraînement si les données échouent aux attentes (non-nullité, bornes, volume).
- Promotion = simple déplacement de l'alias MLflow @production. Décision tracée et reproductible.

Dérive surveillée, performance pilotée

Deux niveaux : la donnée qui entre (drift) et le service qui tourne (métriques).

D R I F T — E V I D E N T L Y

- Référence (train) vs courant (échantillon récent)
- Double critère : part de colonnes driftées > 0,2...
- ...OU feature sentinelle (budget, taille) franchit son seuil JS
- Tâche non bloquante dans le DAG de réentraînement

S E R V I C E — G R A F A N A

- Latence p50 / p95 de /recommand
- Débit, requêtes cumulées, taux d'erreurs
- Feedback par action (approved / rejected)
- Source Prometheus (instrumentation FastAPI)

C E Q U I D É C L E N C H E U N E A C T I O N

Drift détecté → rapport HTML horodaté · Réentraînement échoue qualité → rollback automatique · Latence p95 > 300 ms → alerte Grafana.

Choix d'architecture & arbitrages

Chaque décision est documentée dans le repo — 8 ADR au format MADR.

Reco en deux étages

Scalable, interprétable, modulaire vs modèle end-to-end opaque.

LightGBM pour le re-ranker

Excellent sur tabulaire en faible volume, rapide CPU, interprétable.

Serving via alias MLflow

Promotion / rollback instantanés sans redéploiement.

Promotion conditionnelle + rollback

Protège la production contre toute régression silencieuse.

Drift à double critère

Sensible aux dérives globales ET localisées (features sentinelles).

Diversification du slate

Sélection composable (max 2/type, 3/couleur), testée unitairement.

Fait pour ce bloc · limites assumées

Le scope du Bloc 4 est volontairement bordé ; les limites sont documentées.

BLOC 4 – LIVRÉ

- Reco 2 étages (CLIP + LightGBM), 72 tests
- API FastAPI + alias MLflow @production
- CI/CD GitHub Actions + manifestes K8s
- Réentraînement Airflow (promotion conditionnelle)
- Monitoring drift (Evidently) + Grafana
- Interface de démonstration (séance → planche)

LIMITES ASSUMÉES

- Clientèle féminine (hors-distribution sinon)
- Scores sur données synthétiques → rang affiché, pas score
- Pas de compatibilité inter-pièces (score par pièce)
- Métriques offline ; A/B test = étape suivante
- Retrieval pgvector adapté au persona, pas au web-scale

C O N C L U S I O N

Une solution d'IA industrialisée, de l'entraînement à la production.

- Modèle, API, CI/CD, réentraînement et monitoring : tous opérationnels et testés.
- Boucle complète : la décision de la conseillère nourrit le réentraînement hebdomadaire.
- Architecture reproductible, versionnée, documentée par 8 ADR et une model card.

`github.com/princebn/miroir · bloc4-mlops/`